

## 10.5 GMM 的假定

在球型扰动项的假定下，2SLS 最有效率。如果存在异方差或自相关，则存在更有效的方法，即“广义矩估计”(Generalized Method of Moments, 简记 GMM)。

GMM 之于 2SLS，正如 GLS 之于 OLS。

**假定 10.1** 线性假定(linearity)

$$y_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \quad (i = 1, \dots, n)$$

其中， $\mathbf{x}_i \equiv (x_{i1} \ x_{i2} \ \cdots \ x_{iK})'$  为第  $i$  个观测数据。

## 假定 10.2 渐近独立的平稳过程

记  $L$  维工具变量为  $\mathbf{z}_i$  (可能与  $\mathbf{x}_i$  重叠),  $\mathbf{w}_i$  由  $\{y_i, \mathbf{x}_i, \mathbf{z}_i\}$  中不重复的变量构成且不含常数项。随机过程  $\{\mathbf{w}_i\}$  为渐近独立的平稳过程。

## 假定 10.3 工具变量的正交性

所有工具变量  $\mathbf{z}_i$  均为“前定”，即与同期扰动项正交。定义  $L$  维列向量  $\mathbf{g}_i \equiv \mathbf{z}_i \varepsilon_i$ ，则  $E(\mathbf{g}_i) = E(\mathbf{z}_i \varepsilon_i) = \mathbf{0}$ 。

## 假定 10.4 秩条件

$L \times K$  维矩阵  $E(\mathbf{z}_i \mathbf{x}_i')$  满列秩，即  $\text{rank}[E(\mathbf{z}_i \mathbf{x}_i')] = K$ 。记  $\boldsymbol{\Sigma}_{ZX} \equiv E(\mathbf{z}_i \mathbf{x}_i')$ 。

**假定 10.5**  $\{\mathbf{g}_i\}$  为鞅差分序列，其协方差矩阵  $\mathbf{S} \equiv E(\mathbf{g}_i \mathbf{g}_i') = E(\varepsilon_i^2 \mathbf{z}_i \mathbf{z}_i')$  为非退化矩阵。

**假设 10.6** 四阶矩  $E[(x_{ik} z_{ij})^2]$  存在且有限， $\forall i, j, k$  (finite fourth moments)。

## 10.6 GMM 的推导

与总体矩条件  $E(\mathbf{g}_i) = E(\mathbf{z}_i \varepsilon_i) = \mathbf{0}$  相对应的样本矩条件为

$$\mathbf{g}_n(\hat{\boldsymbol{\beta}}) \equiv \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i (y_i - \mathbf{x}_i' \hat{\boldsymbol{\beta}}) = \mathbf{0}$$

此联立方程组，未知数  $\hat{\boldsymbol{\beta}}$  有  $K$  个，方程个数为  $L$  个 ( $\mathbf{z}_i$  的维度)。

如果  $L < K$ ，为不可识别，则  $\hat{\beta}$  有无穷多解。

如果  $L = K$ ，为恰好识别，则  $\hat{\beta}$  有唯一解，即  $\hat{\beta}_{IV}$ 。

如果  $L > K$ ，为过度识别，则  $\hat{\beta}$  无解。传统的矩估计法行不通。

虽然无法找到  $\hat{\beta}$  使得  $\mathbf{g}_n(\hat{\beta}) = \mathbf{0}$ ，总可以找到  $\hat{\beta}$ ，使得向量  $\mathbf{g}_n(\hat{\beta})$  尽可能地接近  $\mathbf{0}$ ，比如，使二次型  $\left(\mathbf{g}_n(\hat{\beta})\right)' \left(\mathbf{g}_n(\hat{\beta})\right)$  最小。

更一般地，用“权重矩阵” (weighting matrix)  $W$  来构成二次型。

假设 $\hat{W}$ 为 $L \times L$ 维对称正定矩阵(可依赖于样本), 且 $\text{plim}_{n \rightarrow \infty} \hat{W} = W$ , 其中 $W$ 为非随机的对称正定矩阵。定义最小化的目标函数为

$$\min_{\hat{\beta}} J(\hat{\beta}, \hat{W}) \equiv n \left( g_n(\hat{\beta}) \right)' \hat{W} \left( g_n(\hat{\beta}) \right)$$

其中, 因子 $n$ 不影响最小化。定义“GMM 估计量”为此无约束二次型最小化问题的解(Hansen, 1982):

$$\hat{\beta}_{\text{GMM}}(\hat{W}) \equiv \arg\min_{\hat{\beta}} J(\hat{\beta}, \hat{W})$$

GMM 估计量取决于权重矩阵 $\hat{W}$ 。对 $\hat{W}$ 的自由选择是 GMM 的最大优点之一, 可通过最优地选择 $\hat{W}$ 使 $\hat{\beta}_{\text{GMM}}$ 最有效。

不同矩条件的强弱程度一般不同，强的矩条件意味着其对应的方差较小(矩阵  $\mathbf{S} = \mathbf{E}(\mathbf{g}_i \mathbf{g}_i')$  的主对角线元素)，是比较紧的约束，故会通过  $\hat{\mathbf{W}}$  得到较大的权重。

$\mathbf{g}_n(\hat{\boldsymbol{\beta}})$  是  $\hat{\boldsymbol{\beta}}$  的一次函数，故  $J(\hat{\boldsymbol{\beta}}, \hat{\mathbf{W}})$  是  $\hat{\boldsymbol{\beta}}$  的二次(型)函数，通过向量微分可得到其最小化问题的解：

$$\hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{W}}) = (\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1} \mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{Zy}}$$

$$\text{其中, } \mathbf{S}_{\text{ZX}} \equiv \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \mathbf{x}_i', \quad \mathbf{S}_{\text{Zy}} \equiv \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i y_i \circ$$

秩条件  $\text{rank}[\mathbf{E}(\mathbf{z}_i \mathbf{x}_i')] = K$  及  $\hat{\mathbf{W}}$  正定保证在大样本下， $(\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1}$  存在。

在恰好识别情况下， $\mathbf{S}_{ZX}$  为方阵，GMM 还原为普通的 IV 法：

$$\hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{W}}) = \mathbf{S}_{ZX}^{-1} \underbrace{\hat{\mathbf{W}}^{-1} \mathbf{S}_{ZX}'^{-1} \mathbf{S}_{ZX}' \hat{\mathbf{W}}}_{=I} \mathbf{S}_{Zy} = \mathbf{S}_{ZX}^{-1} \mathbf{S}_{Zy} = \hat{\boldsymbol{\beta}}_{\text{IV}}$$

故 GMM 确实是矩估计的推广。

只有在过度识别的情况下，才有必要使用 GMM。

## 10.7 GMM 的大样本性质

定理(GMM 估计量的大样本性质)

(1) ( $\hat{\beta}_{\text{GMM}}$  为一致估计) 在假定 10.1-10.4 之下,  
 $\text{plim}_{n \rightarrow \infty} \hat{\beta}_{\text{GMM}}(\hat{W}) = \beta$ 。

(2) ( $\hat{\beta}_{\text{GMM}}$  为渐近正态) 如果假定 10.3 (即  $E(\mathbf{g}_i) = \mathbf{0}$ ) 强化为假定 10.5 (即  $\{\mathbf{g}_i\}$  为鞅差分序列), 则

$$\sqrt{n}(\hat{\beta}_{\text{GMM}} - \beta) \xrightarrow{d} N(\mathbf{0}, \text{Avar}(\hat{\beta}_{\text{GMM}}))$$

其中,  $\text{Avar}(\hat{\beta}_{\text{GMM}}) = (\Sigma'_{\text{ZX}} W \Sigma'_{\text{ZX}})^{-1} \Sigma_{\text{ZX}} W S W \Sigma_{\text{ZX}} (\Sigma'_{\text{ZX}} W \Sigma_{\text{ZX}})^{-1}$ ,  
 $S = E(\mathbf{g}_i \mathbf{g}_i') = E(\varepsilon_i^2 \mathbf{z}_i \mathbf{z}_i')$ ,  $\Sigma_{\text{ZX}} \equiv E(\mathbf{z}_i \mathbf{x}_i')$ 。



(3) ( $\text{Avar}(\hat{\boldsymbol{\beta}}_{\text{GMM}})$ 的一致估计量)如果 $\hat{\mathbf{S}}$ 是 $\mathbf{S}$ 的一致估计量,则在假定 10.2 下,  $\text{Avar}(\hat{\boldsymbol{\beta}}_{\text{GMM}})$ 的一致估计量为

$$\widehat{\text{Avar}(\hat{\boldsymbol{\beta}}_{\text{GMM}})} = (\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1} \mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \hat{\mathbf{S}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}} (\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1}$$

证明: (1) 抽样误差可写为

$$\begin{aligned} \hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{W}}) - \boldsymbol{\beta} &= (\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1} \mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \left( \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i y_i \right) - \boldsymbol{\beta} \\ &= (\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1} \mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \left( \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i (\mathbf{x}'_i \boldsymbol{\beta} + \varepsilon_i) \right) - \boldsymbol{\beta} \\ &= (\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1} \mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \left( \mathbf{S}_{\text{ZX}} \boldsymbol{\beta} + \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i \varepsilon_i \right) - \boldsymbol{\beta} \\ &= (\mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \mathbf{S}_{\text{ZX}})^{-1} \mathbf{S}'_{\text{ZX}} \hat{\mathbf{W}} \bar{\mathbf{g}} \end{aligned}$$

其中,  $\bar{\mathbf{g}} \equiv \frac{1}{n} \sum_{i=1}^n \mathbf{g}_i$ ,  $\mathbf{g}_i \equiv \mathbf{z}_i \varepsilon_i$ 。由于  $(\mathbf{S}'_{ZX} \hat{\mathbf{W}} \mathbf{S}_{ZX})^{-1} \xrightarrow{p} (\boldsymbol{\Sigma}'_{ZX} \mathbf{W} \boldsymbol{\Sigma}_{ZX})^{-1}$ ,  $\mathbf{S}'_{ZX} \hat{\mathbf{W}} \xrightarrow{p} \boldsymbol{\Sigma}'_{ZX} \mathbf{W}$ , 而  $\bar{\mathbf{g}} \xrightarrow{p} E(\mathbf{g}_i) = E(\mathbf{z}_i \varepsilon_i) = \mathbf{0}$ 。因此,  $\hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{W}}) - \boldsymbol{\beta} \xrightarrow{p} \mathbf{0}$ 。

保证 GMM 一致性的最重要条件仍是  $E(\mathbf{z}_i \varepsilon_i) = \mathbf{0}$ , 即工具变量与扰动项正交。

(2) 由于抽样误差  $\hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{W}}) - \boldsymbol{\beta} = (\mathbf{S}'_{ZX} \hat{\mathbf{W}} \mathbf{S}_{ZX})^{-1} \mathbf{S}'_{ZX} \hat{\mathbf{W}} \bar{\mathbf{g}}$ , 故  $\sqrt{n}(\hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{W}}) - \boldsymbol{\beta}) = (\mathbf{S}'_{ZX} \hat{\mathbf{W}} \mathbf{S}_{ZX})^{-1} \mathbf{S}'_{ZX} \hat{\mathbf{W}} (\sqrt{n} \bar{\mathbf{g}})$ 。

根据假定 10.5 及鞅差分序列的中心极限定理,  $\sqrt{n} \bar{\mathbf{g}} \xrightarrow{d} N(\mathbf{0}, \mathbf{S})$ , 其中  $\mathbf{S} \equiv E(\mathbf{g}_i \mathbf{g}_i') = E(\varepsilon_i^2 \mathbf{z}_i \mathbf{z}_i')$ 。

由于  $\sqrt{n}(\hat{\beta}_{\text{GMM}}(\hat{W}) - \beta)$  是  $\sqrt{n} \bar{g}$  的线性组合，故  $\sqrt{n}(\hat{\beta}_{\text{GMM}}(\hat{W}) - \beta) \xrightarrow{d} N(\mathbf{0}, \text{Avar}(\hat{\beta}_{\text{GMM}}))$ 。由于  $(S'_{\text{ZX}} \hat{W} S_{\text{ZX}})^{-1} \xrightarrow{p} (\Sigma'_{\text{ZX}} W \Sigma_{\text{ZX}})^{-1}$ ， $S'_{\text{ZX}} \hat{W} \xrightarrow{p} \Sigma'_{\text{ZX}} W$ ，故

$$\text{Avar}(\hat{\beta}_{\text{GMM}}) = (\Sigma'_{\text{ZX}} W \Sigma_{\text{ZX}})^{-1} \Sigma'_{\text{ZX}} W S W \Sigma_{\text{ZX}} (\Sigma'_{\text{ZX}} W \Sigma_{\text{ZX}})^{-1}$$

其中， $(\Sigma'_{\text{ZX}} W \Sigma_{\text{ZX}})^{-1}$  为对称矩阵。

(3) 由于  $\hat{S} \xrightarrow{p} S$ ，而且  $S_{\text{ZX}} \xrightarrow{p} \Sigma_{\text{ZX}}$ ， $\hat{W} \xrightarrow{p} W$ ，故估计量  $\widehat{\text{Avar}(\hat{\beta}_{\text{GMM}})} = \underbrace{(S'_{\text{ZX}} \hat{W} S_{\text{ZX}})^{-1} S'_{\text{ZX}} \hat{W}}_{\text{面包}} \underbrace{\hat{S} \hat{W} S_{\text{ZX}}}_{\text{菜}} \underbrace{(S'_{\text{ZX}} \hat{W} S_{\text{ZX}})^{-1}}_{\text{面包}}$  是  $\text{Avar}(\hat{\beta}_{\text{GMM}})$  的一致估计量。形式上也是一个夹心估计量。

**命题** 在假定 10.1、假定 10.2 与假定 10.6 下(四阶矩存在), 对于  $\boldsymbol{\beta}$  的任何一致估计量  $\hat{\boldsymbol{\beta}}$ , 定义残差  $e_i \equiv y_i - \mathbf{x}_i' \hat{\boldsymbol{\beta}}$ , 则  $s^2 \equiv \frac{1}{n} \sum_{i=1}^n e_i^2$  是  $\sigma^2 \equiv E(\varepsilon_i^2)$  的一致估计, 而且  $\hat{\mathbf{S}} \equiv \frac{1}{n} \sum_{i=1}^n e_i^2 \mathbf{z}_i \mathbf{z}_i'$  是  $\mathbf{S} \equiv E(\varepsilon_i^2 \mathbf{z}_i \mathbf{z}_i')$  的一致估计。

**命题** 使  $\text{Avar}(\hat{\boldsymbol{\beta}}_{\text{GMM}})$  最小化的“最优权重矩阵”(optimal weighting matrix)为  $\hat{\mathbf{W}} = \hat{\mathbf{S}}^{-1}$ 。

**定义** 使用  $\hat{\mathbf{S}}^{-1}$  为权重矩阵的 GMM 估计量被称为“效率 GMM”(efficient GMM)或“最优 GMM”(optimal GMM)。

由于 2SLS 一致，用 2SLS 的残差来计算  $\hat{\mathbf{S}} \equiv \frac{1}{n} \sum_{i=1}^n e_i^2 \mathbf{z}_i \mathbf{z}_i'$  也一致。

两步最优 GMM 估计：

第一步：使用 2SLS，得到残差，计算  $(p_t, q_t)$ 。

第二步：最小化  $J(\hat{\boldsymbol{\beta}}, \hat{\mathbf{S}}^{-1})$ ，得到  $\hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{S}}^{-1})$ 。

实际操作中，常使用“迭代法”(iterative GMM)直至估计值收敛，即用第二步所获残差再来计算  $\hat{\mathbf{S}}$ ，然后再求  $\hat{\boldsymbol{\beta}}_{\text{GMM}}(\hat{\mathbf{S}}^{-1})$ ，以此类推。

**命题** 在条件同方差的情况下，最优 GMM 就是 2SLS。

**证明：**假设  $E(\varepsilon_i^2 | \mathbf{z}_i) = \sigma^2 > 0$  (条件同方差)，则根据迭代期望定律，

$$\mathbf{S} \equiv E(\mathbf{z}_i \mathbf{z}_i' \varepsilon_i^2) = E_{\mathbf{z}_i} E(\mathbf{z}_i \mathbf{z}_i' \varepsilon_i^2 | \mathbf{z}_i) = E_{\mathbf{z}_i} \left[ \mathbf{z}_i \mathbf{z}_i' E(\varepsilon_i^2 | \mathbf{z}_i) \right] = \sigma^2 E(\mathbf{z}_i \mathbf{z}_i')$$

因此， $\tilde{\mathbf{S}} \equiv s^2 \mathbf{S}_{ZZ}$  是  $\mathbf{S}$  的一致估计量，其中  $\mathbf{S}_{ZZ} \equiv \frac{1}{n} \mathbf{Z}'\mathbf{Z}$ 。

使用  $\tilde{\mathbf{S}}^{-1} = (s^2 \mathbf{S}_{ZZ})^{-1}$  为最优权重矩阵，则最优 GMM 估计量为

$$\begin{aligned} \hat{\boldsymbol{\beta}}_{\text{GMM}}(\tilde{\mathbf{S}}^{-1}) &= \left( \mathbf{S}'_{ZX} (s^2 \mathbf{S}_{ZZ})^{-1} \mathbf{S}_{ZX} \right)^{-1} \mathbf{S}'_{ZX} (s^2 \mathbf{S}_{ZZ})^{-1} \mathbf{S}_{Zy} \\ &= \left( \mathbf{S}'_{ZX} \mathbf{S}_{ZZ}^{-1} \mathbf{S}_{ZX} \right)^{-1} \mathbf{S}'_{ZX} \mathbf{S}_{ZZ}^{-1} \mathbf{S}_{Zy} \end{aligned}$$

由于  $\mathbf{S}_{ZX} \equiv \frac{1}{n} \mathbf{Z}'\mathbf{X}$ ,  $\mathbf{S}_{ZZ} \equiv \frac{1}{n} \mathbf{Z}'\mathbf{Z}$ ,  $\mathbf{S}_{Zy} \equiv \frac{1}{n} \mathbf{Z}'\mathbf{y}$ , 故

$$\begin{aligned}\hat{\boldsymbol{\beta}}_{\text{GMM}}(\tilde{\mathbf{S}}^{-1}) &= \left( \frac{1}{n} \mathbf{X}'\mathbf{Z} \cdot n(\mathbf{Z}'\mathbf{Z})^{-1} \cdot \frac{1}{n} \mathbf{Z}'\mathbf{X} \right)^{-1} \frac{1}{n} \mathbf{X}'\mathbf{Z} \cdot n(\mathbf{Z}'\mathbf{Z})^{-1} \frac{1}{n} \mathbf{Z}'\mathbf{y} \\ &= \left( \mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{y} \equiv \hat{\boldsymbol{\beta}}_{2\text{SLS}}\end{aligned}$$

在条件同方差的情况下，两步最优 GMM 可省略为一步。因为两步最优 GMM 中第一步的目的只是得到  $\hat{\mathbf{S}}^{-1}$ ，而在条件同方差假定下，可直接令  $\hat{\mathbf{S}}^{-1} = \mathbf{S}_{ZZ}^{-1}$ 。

故 2SLS 也称为“一步 GMM”。

## GMM 的过度识别检验(Overidentification Test or Hansen's $J$ Test)

在恰好识别的情况下，GMM 最小化的目标函数  $J(\hat{\beta}_{\text{GMM}}, \hat{S}^{-1}) = 0$ 。

在过度识别的情况下，如果所有的过度识别约束都成立，则目标函数  $J(\hat{\beta}_{\text{GMM}}, \hat{S}^{-1})$  应该离 0 不远。

如果  $J(\hat{\beta}_{\text{GMM}}, \hat{S}^{-1})$  大于 0 很多，则可倾向于认为某些过度识别约束不成立。

在原假设“ $H_0$ : 所有矩条件均成立”的情况下，目标函数本身就是检验统计量



$$J(\hat{\beta}_{\text{GMM}}, \hat{S}^{-1}) \xrightarrow{d} \chi^2(L-K)$$

其中， $(L-K)$ 为过度识别约束的个数，因为在估计 $\hat{\beta}_{\text{GMM}}$ 的过程中失去了 $K$ 个自由度。

在条件同方差的情况下， $J$ 统计量与 Sargan 统计量相等。

### 检验部分工具变量的正交性(Testing Subsets of Orthogonality Condition)

如果过度识别检验拒绝“所有工具变量均为外生”的原假设，则怀疑部分工具变量不满足正交性(外生性)。

假设在 $L$ 个工具变量 $\mathbf{z}_i$ 中，已知前 $L_1$ 个工具变量 $\mathbf{z}_{i1}$ 满足正交性，而怀疑后 $(L - L_1)$ 个工具变量 $\mathbf{z}_{i2}$ 不满足正交性。

检验原假设 “ $H_0: E(\mathbf{z}_{i2}\varepsilon_i) = 0$ ”。

进行此检验的前提条件是 $L_1 \geq K$ ，保证即使仅用前 $L_1$ 个工具变量 $\mathbf{z}_{i1}$ 进行估计，该模型也为恰好识别。

如果 $L_1 \geq K$ ，则可分别用所有 $L$ 个工具变量 $\mathbf{z}_i$ 或前 $L_1$ 个工具变量 $\mathbf{z}_{i1}$ 进行 GMM 估计，记相应的 $J$ 统计量为 $J$ 与 $J_1$ 。

如果将后 $(L - L_1)$ 个工具变量 $\mathbf{z}_{i2}$ 也用于 GMM 估计，使得 $J$ 统计量大大增加，则倾向于拒绝原假设 “ $H_0: E(\mathbf{z}_{i2}\varepsilon_i) = 0$ ”。

可以证明：

$$C \equiv J - J_1 \xrightarrow{d} \chi^2(L - L_1)$$

其中， $C$  统计量称为“GMM 距离” (GMM distance)统计量或“Sargan 差” (difference-in-Sargan)统计量，因为它是两个 GMM 估计的 Sargan-Hansen 统计量之差。

自由度为 $(L - L_1)$ ，即怀疑正交性不成立的工具变量个数。

## 在存在自相关的情况下使用 GMM

在时间序列数据中，即使存在自相关，也仍可使用 GMM，只要采用异方差自相关稳健的标准误来进行统计推断就行。